OpenGuide

开源项目新手贡献智能向导

输入 GitHub 仓库 URL，生成**分阶段、可回溯原文**的新手贡献路线图。未通过原文核验的命令隐藏，执行与用户效果另行验证。

申报方向	保持方向一：开源赋能的 AI 应用创新
作品名称	OpenGuide开源贡献向导
验证状态	工程验证已进行；用户效果与上游贡献闭环待补充
许可	MIT
文档版本	2026-10-18 · 修订工作稿

目录

1. 作品简介与选题论证
    1.1 问题
    1.2 我们的答案
    1.3 需求与验证边界
2. 系统设计：四段管线
    2.1 为什么不是「clone 全文 → LLM 写总结」
    2.2 M1：四视角分层索引（技术差异点核心）
    2.3 M2：证据锚点校验（防幻觉核心）
    2.4 无 Key 也能跑（演示与离线评审友好）
3. 关键工程决策
4. 开源清单与引用
5. 验证证据：四层评测
    5.1 五个指标（benchmark/metrics.py，规则化、确定性）
    5.2 结果口径与实验状态
    5.3 golden 仓库集
    5.4 自动测试
    5.5 第二轮命令实跑（固定提交与环境）
    5.6 连续流程与执行上下文
    5.7 固定参考与公平对照（第四轮）
6. 真实贡献记录（方向三佐证）
7. 运行与复现
    7.1 一键部署（评审冷启动推荐）
    7.2 本地开发
    7.3 接口
8. 项目路线图与开源计划
    8.1 已交付
    8.2 后续计划
    8.3 开源计划
9. 隐私、授权与 AI 辅助开发
附：文档索引

> 当前状态：见 国赛完善与验收记录。本文件与 PDF 为修订工作稿；真实用户效果与贡献证据尚待补齐。

作品名称：OpenGuide开源贡献向导 **申报方向**：保持现有方向一（开源赋能的 AI 应用创新）；申报分类如需调整，先由团队确认。项目服务于开源新手贡献场景。 **一句话定位**：输入一个 GitHub 仓库 URL，输出一份**带证据、可执行、会陪你走完每一步**的新手贡献路线图。

1. 作品简介与选题论证

1.1 问题

开源生态最大的摩擦不在"写代码"，而在**第一次贡献之前的那段路**：环境怎么搭、测试怎么跑、 第一个 issue 怎么选、PR 怎么提。这些信息散落在 README、CONTRIBUTING、docs/、Makefile、 CI workflow 与 issue 标签里，新手既不知道去哪找，也不知道找得对不对。

通用聊天机器人能给一段"看起来像那么回事"的答案，但它**无法保证答案来自这个仓库**—— 编造的安装命令、不存在的 issue 编号，正是新手最容易被坑的地方。

1.2 我们的答案

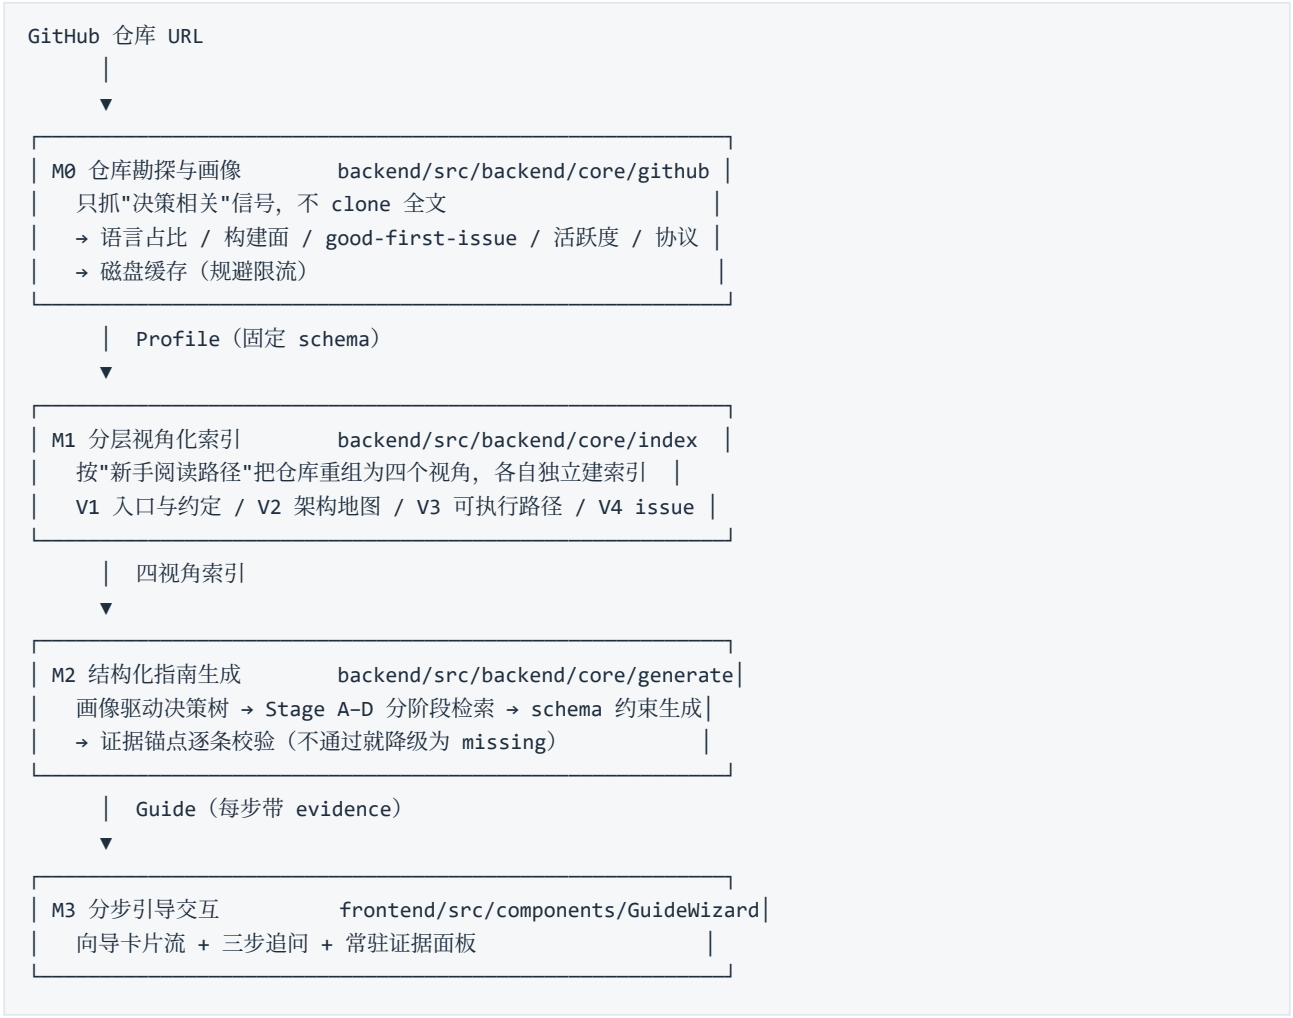
OpenGuide 把非结构化仓库加工成**结构化、可检索、带证据、可分步执行的操作手册**， 并守住一条硬边界：

> **无证据不宣称。** 每条建议都要能回溯到仓库里的真实文件或 issue；不能确认的， 宁可标注 `missing` 并建议提问，也不编造安装命令或 issue 编号。

1.3 需求与验证边界

目标用户是有基础编程经验、尚未完成首次贡献的学生。项目解决查找环境与测试说明、识别任务、按步骤操作的问题。 目前尚缺真实用户实验与可核验的上游贡献闭环，具体补充方案见 `user_study_protocol.md`。 不从功能实现或测试通过直接推断学习效果。

2. 系统设计：四段管线



2.1 为什么不是「clone 全文 → LLM 写总结」

现有流程面临的三个问题，正是四段管线的设计依据：

失配	说明	对策
规模失配	数千文件塞不进上下文，噪声淹没信号	M0 只抓决策相关信号；M1 分视角建索引
信息类型失配	"如何搭环境"分散在 README / CONTRIBUTING / docs / workflow	V3 把可执行路径**跨文件聚合**到一起
能力前提失配	新手卡住时不会定位问题	指南带**预期结果**与**失败分支**；三步追问兜底

2.2 M1：四视角分层索引（技术差异点核心）

通用代码分块未必能直接回答上手任务；本项目检验按任务路由检索是否有助于找到相关说明。 我们按新手阅读路径重组为四个视角，各视角独立建索引：

视角	内容来源	回答什么
V1 入口与约定	README + CONTRIBUTING + 规范 + license	贡献流程、协议边界
V2 架构地图	目录树 + 顶层结构	代码怎么组织、改哪在哪
V3 可执行路径	构建清单 + Makefile/脚本 + 安装章节	**怎么跑起来 / 跑测试**
V4 issue 槽位	good-first-issue 标题/正文/标签	现在能做什么

V3 的准入规则值得单说：一个文档只有**真的含命令行**（或本身就是构建文件）才进 V3。 这条规则是被真实缺陷逼出来的——`psf/requests` 的 `docs/dev/contributing.rst` 是纯叙述文档 （一条命令都没有），早期版本仅凭文件名含 `contribut` 就把它收进 V3，它靠 11 个分块把 真正含 `python -m pytest tests` 的 `Makefile` 挤出了检索结果，导致"怎么跑测试"答不出来。 同类被排除的还有 changelog / history / authors——它们是"变更与署名"，不是可执行路径。

2.3 M2：证据锚点校验（防幻觉核心）

生成不是"让模型自由发挥"，而是**先检索、再填空、最后审计**：

1. 每个 Stage 只拿到该阶段检索到的仓库原文片段；
2. 模型按严格 JSON schema 填写 `GuideStep`（title / command / expected / fail_hints / evidence）；
3. **证据审计**：分别验证来源路径、行号、引用原文和命令原文；

无法核验则标记 `missing`；未通过原文核验的命令隐藏。原文匹配不能证明语义正确或实际执行成功；

1. 仍缺出处时定向检索，只有引用或命令能在候选原文核验时才回填；不能将无关文件作为证据。

2.4 无 Key 也能跑（演示与离线评审友好）

未配置大模型时，生成走**确定性启发式**路径：用规则从检索到的原文里挑出**属于该阶段** 的真实命令（A 安装 / B 测试 / C issue / D git·PR），挑不到就留空。 这条路让 CI 与离线评审无需任何密钥即可跑通全链路。

3. 关键工程决策

决策	理由
不 clone 全文，只走 GitHub API	省带宽、可缓存、能在无 git 环境运行；配合 TTL 磁盘缓存规避限流
向量检索可降级	chromadb 不可用或嵌入模型缺失时，回退到确定性的词元重叠检索，测试与演示在离线环境仍可跑
证据来源保留仓库真实大小写	前端据此拼"打开原始出处"链接，大小写错了会 404
意图路由用整词匹配	早期用子串匹配，短词 `pr` 会命中 `improve`/`progress`，把问题错误路由到"贡献流程"
LLM 配置只存会话内存	Key 不落盘、不进日志；页面右上角可临时填写

4. 开源清单与引用

本项目以 **MIT** 许可发布（见 `LICENSE`）。**不自称纯开源**：编排、分层索引、证据校验、 评测体系为团队自主实现；通用大模型走商业 API。

完整的第三方组件、开源模型与商业服务清单及其许可条件，逐项列于 `third_party_disclosure.md`。

5. 验证证据：四层评测

评测分四层，**口径红线**：仓库内样例/烟测**不得**宣称生成质量；任何质量数字必须能回溯到 **人工复核过的 golden 仓库集**。详见 `../benchmark/README.md`。

层	命令	作用	是否产出质量数字
L1 烟测	`python -m benchmark.l1_smoke`	离线验证 URL→画像→决策树→索引→生成→schema→证据 全链路通	**否**（明确不产出）
L2 黄金评估	`python -m benchmark.l2_golden.runner`	对 golden 仓库跑真实生成，按五维度打分	是（人工复核集）
L3 消融	`python -m benchmark.l3_ablation.runner`	同批仓库对比「朴素单次生成」vs「分层四视角管线」，含耗时	是（同基准防漂移）
L4 真实贡献	`python -m benchmark.l4_contribution.runner`	用本产品实际提交 PR 的记录	记录，非评分

5.1 五个指标（`benchmark/metrics.py`，规则化、确定性）

指标	含义
`step_coverage` 步骤完整率	生成的步骤覆盖了多少 golden 步骤
`evidence_hit` 证据命中率	生成步骤的证据来源能否解析到真实仓库文件/issue
`command_correct` 参考命令匹配率	严格匹配动作、目标和参数，仅容许明确的等价形式
`command_exec` 命令可执行率	命令能否在真实 clone 上执行（"跑得动吗"）
`assert_rate` 非缺失来源比例	非 `missing` 步骤占比，不表示事实正确性

另记录 **单仓库生成耗时**（`elapsed_s`），用于回答"分层管线多换来了什么、多花了多少时间"。

5.2 结果口径与实验状态

2026-10-06 的旧 L2 结果来自规则生成；旧 L3 使用人工构造的 fake 基线，只能演示错误检测，不能证明真实模型效果。 命令匹配和步骤覆盖定义已修复，旧结果不能与新指标直接比较。原始数据保留在 `benchmark/reports/`，不得作为当前版本质量结论。

新增 `python -m benchmark.controlled_ablation`，使用真实模型、固定源码快照、四组对照、原始输出、失败与 token 用量记录。 证据审计组复用原始生成，避免重新采样混淆。当前结果仅作探索性分析，golden 还需按快照 SHA 人工复核，命令执行与用户效果另行验证。 本轮完成五仓库探索性实验，63 次成功模型调用，未测命令执行和用户效果；四视角并未证明全面优于普通 RAG。详见 `real_model_findings_20261018.md`、`competition_readiness.md` 和 `evaluation_report.md`。

5.3 golden 仓库集

旧标注记录中 5 个仓库标记为 `verified: true`；本轮尚需按固定 SHA 重新人工复核。以下为原集合（见 `benchmark/golden/repos.json`）：

仓库	类型	覆盖特征
`psf/requests`	Python 库	文档最全、最典型的新手入口
`pallets/click`	Python CLI 框架	pyproject + pytest，构建面干净
`cookiecutter/cookiecutter`	项目脚手架	脚手架场景代表
`mochajs/mocha`	JavaScript 测试框架	**跨语言**（package.json + npm test）
`camelot-dev/camelot`	PDF 表格抽取	依赖较重，验证鲁棒性

5.4 自动测试

套件	命令	数量
后端单测/集成	`python -m pytest backend/tests -q`	**以当前测试运行记录为准**
评测体系单测	`python -m pytest benchmark/tests -q`	**以当前测试运行记录为准**
合计	—	**以当前测试运行记录为准**
CI	`.github/workflows/ci.yml`	后端测试 + 前端构建 + 密钥扫描

CI 全程走 hermetic 路径（`USE_CHROMA=false`），**不下载任何嵌入模型**，秒级完成。

5.5 第二轮命令实跑（固定提交与环境）

Requests 开发依赖安装通过；完整 CI 为 625 passed、6 failed、3 skipped、1 xfailed，整体失败。另选的数据结构子集 24 passed，不能替代全量结果。 Click 直接 pytest 基线为 2179 passed、107 skipped、31000 deselected、1 xfailed，不代表 tox random 或 stress 环境通过。 Requests 的 Windows 符号链接问题经定位，证书单例复测通过；完整 CI 没有在链接修复后重跑，其他网络/代理相关失败仍待解决。

本轮据此增加简单 make 目标原文展开、保存指南执行记录、抓取缺失状态和符号链接提示。执行计划、原始模型回放与实际执行结果分开记录，不将它们混成一个准确率。 详见 `execution_findings_20261018.md` 与 `benchmark/reports/execution_validation_20261018.json`。

5.6 连续流程与执行上下文

克隆仓库已前移到安装之前，步骤重新编号并标出流程前置关系；Makefile 命令显示按构建文件推导的执行目录和所需输入路径，资料不足时明确待确认。基础完成检查与仓库原文预期分开展示。 历史执行记录除命令和提交外，还核对已记录的执行目录，不能挪用其他目录的结果。 本轮仅对既有输出作确定性回放，没有新增模型抽样或完整测试结论，详见 `workflow_round3_20261018.md`。

5.7 固定参考与公平对照（第四轮）

两份参考绑定源码 SHA、引用原文与行号，规则检查和三个来源文件的 Git blob 交叉检查通过；它们属于 AI 源码复核，独立人工复核仍待完成。 普通 RAG 改为统一去重索引，路由组关闭专属加分，两个仓库各两次重复完成 36 次模型请求。Requests 的两次参考匹配中，全局与路由持平；Click 专项命令参考与基础测试任务存在评价边界，不据此将拒绝编造判为错误。 对照发现克隆说明可能被安装资料挤出，已为环境阶段保留克隆、依赖和运行时资料位置。随后 4 次请求的 Requests 单例覆盖三项参考命令，不能推广为一般提升。 本轮未新增上游命令执行，模型对照、单例修复和历史实跑分开记录，详见 `evidence_round4_20261018.md`。

6. 真实贡献记录（方向三佐证）

L4 记录"用本产品自己走通一个真实 PR"的闭环证据，落盘于 `benchmark/l4_contribution/records.json`，用一行代码补录：

```
from benchmark.l4_contribution.runner import add_record
add_record("owner", "repo", "pr", "https://github.com/owner/repo/pull/123", "用 OpenGuide 走通的文档改进")
```

状态语义（避免"待补充"被误读成"失败"）：

- `PENDING`：尚无记录（退出码 0，明确标注待补充）
- `OK`：已有记录，逐条打印
- `FAIL`：记录文件损坏（真错误）

> **口径**：没有记录就不会被算作"闭环已完成"——报告明确标 `PENDING`，评审一眼可见此项待补。

7. 运行与复现

7.1 一键部署（评审冷启动推荐）

```
cp .env.example .env          # 可选：填 GITHUB_TOKEN / LLM_API_KEY；不填也能跑
docker compose up --build
# 浏览器打开 http://127.0.0.1:5173
```

前端由 nginx 提供静态站点并把 `/api` 反向代理到后端容器（同源，免 CORS）。 默认 `USE_CHROMA=false` 走确定性检索，**零模型下载、秒级启动**，适合离线评审。

7.2 本地开发

```
# 后端
cd backend && uv sync && uv run uvicorn backend.api.main:app --port 8000
# 前端
cd frontend && pnpm install && pnpm dev     # http://127.0.0.1:5173
```

7.3 接口

方法	路径	说明
POST	`/api/profile`	`{url}` → 仓库画像
POST	`/api/search`	`{url, query, kind?}` → 按视角路由的检索结果
POST	`/api/guide`	`{url, use_llm}` → Stage A–D 结构化指南
POST	`/api/followup`	三步追问：这步太粗 / 看不懂为什么 / 报错了
GET/POST	`/api/llm-config`	会话内 LLM 配置（不回显 Key）
GET	`/health`	存活检查

8. 项目路线图与开源计划

8.1 已交付

- 四段管线（M0 勘探 / M1 分层索引 / M2 结构化生成 / M3 分步引导）全部打通
- 四层评测体系（L1–L4）+ 5 个已人工复核的 golden 仓库
- Docker 一键部署、演示脚本、第三方许可披露、变更记录

8.2 后续计划

方向	内容
评测扩容	golden 集从 5 个扩到 15–20 个，覆盖更多语言与构建系统（Rust / Go / Java）
开源模型对比	用同一评估集对比开源模型与商业模型的输出质量（点题"AI + 开源"，不做过度承诺）
V2 架构视角升级	引入 tree-sitter 符号表，把"改哪个文件"从目录级细化到符号级
追问增强	报错定位接入更多语言生态的规则库
真实贡献	持续用本产品向小仓库提交 PR，滚动更新 L4 记录

8.3 开源计划

本作品以 MIT 许可开源。仓库目前已公开，接受外部 issue 与 PR—— 用自己做的工具来管理自己的新手贡献者，是这个项目最好的验证方式。

9. 隐私、授权与 AI 辅助开发

见 `privacy_and_license.md` 与 `ai_assistance_disclosure.md`。

附：文档索引

文档	内容
task_book.md	任务书（选题论证 / 技术方案 / 里程碑）
demo_script.md	固定证据主线与在线可选演示
video_script.md	演示视频分镜脚本
code_outline.md	代码大纲与接口约定
third_party_disclosure.md	第三方资源与许可披露
privacy_and_license.md	隐私与授权说明
cold_start_checklist.md	提交包冷启动演练记录
evaluation_report.md	评测报告（L2/L3 实测数字与归因）
../output/pdf/OpenGuide- .pdf	本说明的 PDF 版本（提交用）
../tools/render_submission_pdf.py	PDF 生成脚本（改完 Markdown 后重新生成）
changelog.md	变更记录（含修复根因与验证口径）
../benchmark/README.md	评测方法论与口径红线