OpenGuide

开源项目新手贡献智能向导

输入 GitHub 仓库 URL，生成**分阶段、可回溯原文**的新手贡献路线图。未通过原文核验的命令隐藏，执行与用户效果另行验证。

申报方向	保持方向一：开源赋能的 AI 应用创新
作品名称	OpenGuide开源贡献向导
验证状态	工程验证已进行；用户效果与上游贡献闭环待补充
许可	MIT
文档版本	2026-10-21 · 修订工作稿

目录

1. 作品简介与选题论证
    1.1 问题
    1.2 我们的答案
    1.3 需求与验证边界
2. 系统设计：四段管线
    2.1 为什么不是「clone 全文 → LLM 写总结」
    2.2 M1：四视角分层索引（技术差异点核心）
    2.3 M2：证据锚点校验（防幻觉核心）
    2.4 无 Key 也能跑（演示与离线评审友好）
3. 关键工程决策
4. 开源清单与引用
5. 验证证据：四层评测
    5.1 五个指标（benchmark/metrics.py，规则化、确定性）
    5.2 结果口径与实验状态
    5.3 golden 仓库集
    5.4 自动测试
    5.5 第二轮命令实跑（固定提交与环境）
    5.6 连续流程与执行上下文
    5.7 固定参考与公平对照（第四轮）
    5.8 当前产品可靠性与追问核验（2026-10-21）
    5.9 多仓库检查与实际复现（2026-10-21）
6. 真实贡献记录（方向三佐证）
7. 运行与复现
    7.1 一键部署（评审冷启动推荐）
    7.2 本地开发
    7.3 接口
8. 项目路线图与开源计划
    8.1 已交付
    8.2 后续计划
    8.3 开源计划
9. 隐私、授权与 AI 辅助开发
附：文档索引

> 当前状态：见 国赛完善与验收记录。本文件与 PDF 为修订工作稿；真实用户效果与贡献证据尚待补齐。

作品名称：OpenGuide开源贡献向导 **申报方向**：保持现有方向一（开源赋能的 AI 应用创新）；申报分类如需调整，先由团队确认。项目服务于开源新手贡献场景。 **一句话定位**：输入一个 GitHub 仓库 URL，从实际取得的资料生成带原文证据、可逐步核对的新手贡献路线图；资料缺失时待确认，不保证自动完成贡献。

1. 作品简介与选题论证

1.1 问题

开源生态最大的摩擦不在"写代码"，而在**第一次贡献之前的那段路**：环境怎么搭、测试怎么跑、 第一个 issue 怎么选、PR 怎么提。这些信息散落在 README、CONTRIBUTING、docs/、Makefile、 CI workflow 与 issue 标签里，新手既不知道去哪找，也不知道找得对不对。

通用聊天机器人能给一段"看起来像那么回事"的答案，但它**无法保证答案来自这个仓库**—— 编造的安装命令、不存在的 issue 编号，正是新手最容易被坑的地方。

1.2 我们的答案

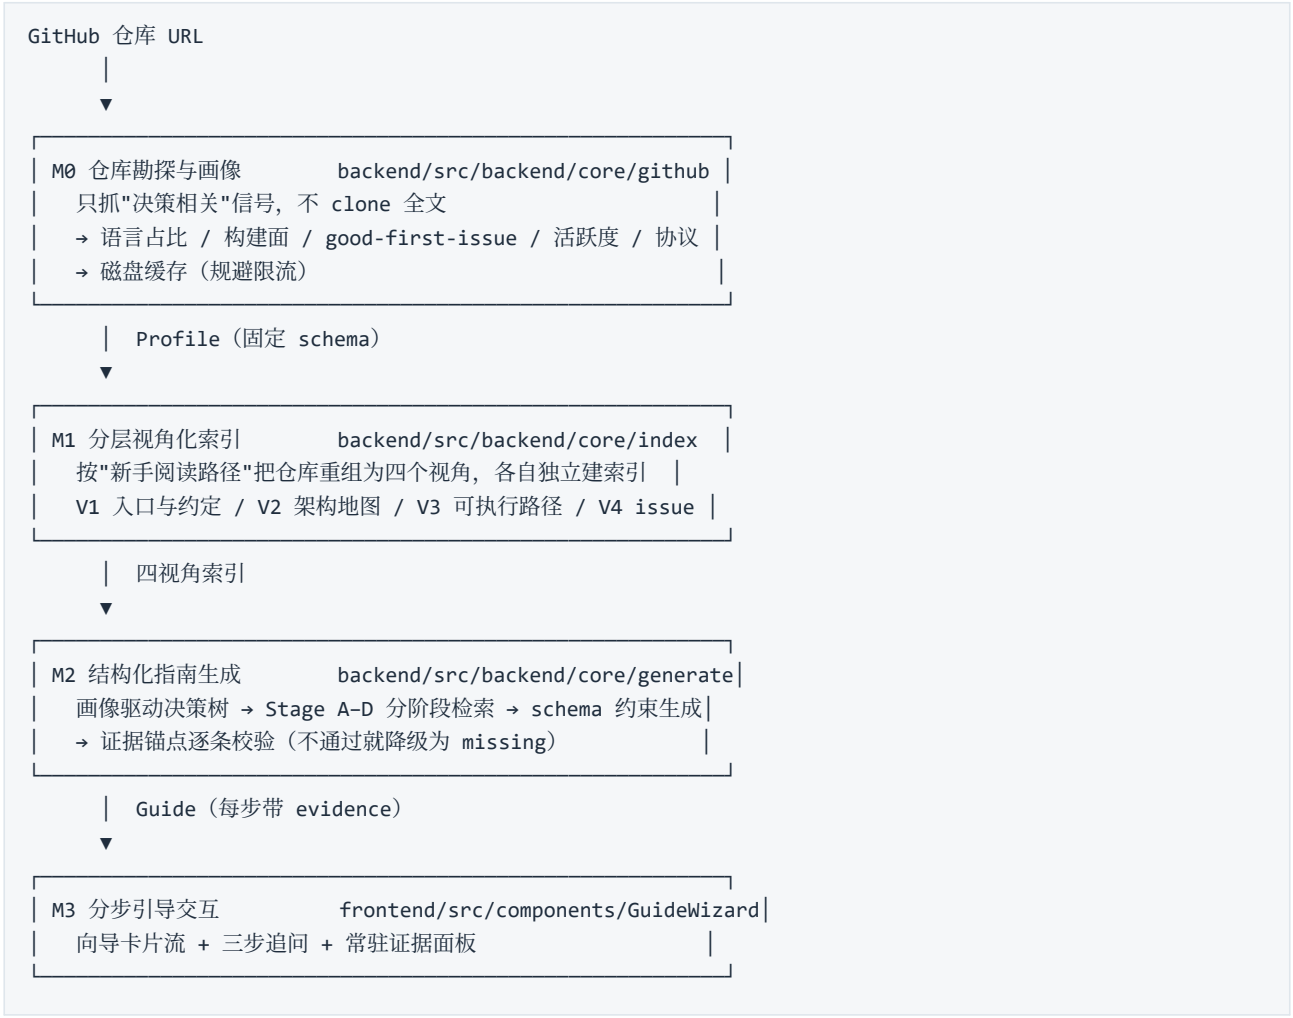
OpenGuide 把非结构化仓库加工成**结构化、可检索、带证据、可分步执行的操作手册**， 并守住一条硬边界：

> **无证据不宣称。** 每条建议都要能回溯到仓库里的真实文件或 issue；不能确认的， 宁可标注 `missing` 并建议提问，也不编造安装命令或 issue 编号。

1.3 需求与验证边界

目标用户是有基础编程经验、尚未完成首次贡献的学生。项目解决查找环境与测试说明、识别任务、按步骤操作的问题。 目前尚缺真实用户实验与可核验的上游贡献闭环，具体补充方案见 `user_study_protocol.md`。 不从功能实现或测试通过直接推断学习效果。

2. 系统设计：四段管线



2.1 为什么不是「clone 全文 → LLM 写总结」

现有流程面临的三个问题，正是四段管线的设计依据：

失配	说明	对策
规模失配	数千文件塞不进上下文，噪声淹没信号	M0 只抓决策相关信号；M1 分视角建索引
信息类型失配	"如何搭环境"分散在 README / CONTRIBUTING / docs / workflow	V3 把可执行路径**跨文件聚合**到一起
能力前提失配	新手卡住时不会定位问题	指南带**预期结果**与**失败分支**；三步追问兜底

2.2 M1：四视角分层索引（技术差异点核心）

通用代码分块未必能直接回答上手任务；本项目检验按任务路由检索是否有助于找到相关说明。 我们按新手阅读路径重组为四个视角，各视角独立建索引：

视角	内容来源	回答什么
V1 入口与约定	README + CONTRIBUTING + 规范 + license	贡献流程、协议边界
V2 架构地图	目录树 + 顶层结构	代码怎么组织、改哪在哪
V3 可执行路径	构建清单 + Makefile/脚本 + 安装章节	**怎么跑起来 / 跑测试**
V4 issue 槽位	good-first-issue 标题/正文/标签	现在能做什么

V3 的准入规则值得单说：一个文档只有**真的含命令行**（或本身就是构建文件）才进 V3。 这条规则是被真实缺陷逼出来的——`psf/requests` 的 `docs/dev/contributing.rst` 是纯叙述文档 （一条命令都没有），早期版本仅凭文件名含 `contribut` 就把它收进 V3，它靠 11 个分块把 真正含 `python -m pytest tests` 的 `Makefile` 挤出了检索结果，导致"怎么跑测试"答不出来。 同类被排除的还有 changelog / history / authors——它们是"变更与署名"，不是可执行路径。

2.3 M2：证据锚点校验（防幻觉核心）

生成不是"让模型自由发挥"，而是**先检索、再填空、最后审计**：

1. 每个 Stage 只拿到该阶段检索到的仓库原文片段；
2. 模型按严格 JSON schema 填写 `GuideStep`（title / command / expected / fail_hints / evidence）；
3. **证据审计**：分别验证来源路径、行号、引用原文和命令原文；

无法核验则标记 `missing`；未通过原文核验的命令隐藏。原文匹配不能证明语义正确或实际执行成功；

1. 仍缺出处时定向检索，只有引用或命令能在候选原文核验时才回填；不能将无关文件作为证据。

2.4 无 Key 也能跑（演示与离线评审友好）

未配置大模型时，生成走**确定性启发式**路径：用规则从检索到的原文里挑出**属于该阶段** 的真实命令（A 安装 / B 测试 / C issue / D git·PR），挑不到就留空。 这条路让 CI 与离线评审无需任何密钥即可跑通全链路。

3. 关键工程决策

决策	理由
不 clone 全文，API 配合固定提交原文下载	省带宽、可缓存、能在无 git 环境运行；减少文件请求占用 API 额度，元信息和 issue 仍可能限流
向量检索可降级	chromadb 不可用或嵌入模型缺失时，回退到确定性的词元重叠检索，测试与演示在离线环境仍可跑
证据来源保留仓库真实大小写	前端据此拼"打开原始出处"链接，大小写错了会 404
意图路由用整词匹配	早期用子串匹配，短词 `pr` 会命中 `improve/progress`，把问题错误路由到"贡献流程"
LLM 配置只存会话内存	Key 不落盘、不进日志；页面右上角可临时填写

4. 开源清单与引用

本项目以 **MIT** 许可发布（见 `LICENSE`）。**不自称纯开源**：编排、分层索引、证据校验、 评测体系为团队自主实现；通用大模型走商业 API。

完整的第三方组件、开源模型与商业服务清单及其许可条件，逐项列于 `third_party_disclosure.md`。

5. 验证证据：四层评测

评测分四层，**口径红线**：仓库内样例/烟测**不得**宣称生成质量；任何质量数字必须能回溯到 **人工复核过的 golden 仓库集**。详见 `../benchmark/README.md`。

层	命令	作用	是否产出质量数字
L1 烟测	`python -m benchmark.l1_smoke`	离线验证 URL→画像→决策树→索引→生成→schema→证据 全链路通	**否**（明确不产出）
L2 黄金评估	`python -m benchmark.l2_golden.runner`	对参考仓库生成并按规则打分	探索性，独立人工复核待完成
L3 消融	`python -m benchmark.l3_ablation.runner`	同批仓库对比「朴素单次生成」vs「分层四视角管线」，含耗时	是（同基准防漂移）
L4 真实贡献	`python -m benchmark.l4_contribution.runner`	用本产品实际提交 PR 的记录	记录，非评分

5.1 五个指标（`benchmark/metrics.py`，规则化、确定性）

指标	含义
`step_coverage` 步骤完整率	生成的步骤覆盖了多少 golden 步骤
`evidence_hit` 证据命中率	生成步骤的证据来源能否解析到真实仓库文件/issue
`command_correct` 参考命令匹配率	严格匹配动作、目标和参数，仅容许明确的等价形式
`command_exec` 命令可执行率	命令能否在真实 clone 上执行（"跑得动吗"）
`assert_rate` 非缺失来源比例	非 `missing` 步骤占比，不表示事实正确性

另记录 **单仓库生成耗时**（`elapsed_s`），用于回答"分层管线多换来了什么、多花了多少时间"。

5.2 结果口径与实验状态

2026-10-06 的旧 L2 结果来自规则生成；旧 L3 使用人工构造的 fake 基线，只能演示错误检测，不能证明真实模型效果。 命令匹配和步骤覆盖定义已修复，旧结果不能与新指标直接比较。原始数据保留在 `benchmark/reports/`，不得作为当前版本质量结论。

新增 `python -m benchmark.controlled_ablation`，使用真实模型、固定源码快照、四组对照、原始输出、失败与 token 用量记录。 证据审计组复用原始生成，避免重新采样混淆。当前结果仅作探索性分析，golden 还需按快照 SHA 人工复核，命令执行与用户效果另行验证。 本轮完成五仓库探索性实验，63 次成功模型调用，未测命令执行和用户效果；四视角并未证明全面优于普通 RAG。详见 `real_model_findings_20261018.md`、

`competition_readiness.md` 和 `evaluation_report.md`。

5.3 golden 仓库集

旧标注记录中 5 个仓库标记为 `verified: true`；本轮尚需按固定 SHA 重新人工复核。以下为原集合（见 `benchmark/golden/repos.json`）：

仓库	类型	覆盖特征
`psf/requests`	Python 库	文档最全、最典型的新手入口
`pallets/click`	Python CLI 框架	pyproject + pytest，构建面干净
`cookiecutter/cookiecutter`	项目脚手架	脚手架场景代表
`mochajs/mocha`	JavaScript 测试框架	**跨语言**（package.json + npm test）
`camelot-dev/camelot`	PDF 表格抽取	依赖较重，验证鲁棒性

5.4 自动测试

套件	命令	数量
后端单测/集成	`python -m pytest backend/tests -q`	**以当前测试运行记录为准**
评测体系单测	`python -m pytest benchmark/tests -q`	**以当前测试运行记录为准**
合计	—	**以当前测试运行记录为准**
CI	`.github/workflows/ci.yml`	后端测试 + 前端构建 + 密钥扫描

CI 全程走 hermetic 路径（`USE_CHROMA=false`），**不下载任何嵌入模型**，秒级完成。

5.5 第二轮命令实跑（固定提交与环境）

Requests 开发依赖安装通过；完整 CI 为 625 passed、6 failed、3 skipped、1 xfailed，整体失败。另选的数据结构子集 24 passed，不能替代全量结果。 Click 直接 pytest 基线为 2179 passed、107 skipped、31000 deselected、1 xfailed，不代表 tox random 或 stress 环境通过。 Requests 的 Windows 符号链接问题经定位，证书单例复测通过；完整 CI 没有在链接修复后重跑，其他网络/代理相关失败仍待解决。

本轮据此增加简单 make 目标原文展开、保存指南执行记录、抓取缺失状态和符号链接提示。执行计划、原始模型回放与实际执行结果分开记录，不将它们混成一个准确率。 详见 `execution_findings_20261018.md` 与 `benchmark/reports/execution_validation_20261018.json`。

5.6 连续流程与执行上下文

克隆仓库已前移到安装之前，步骤重新编号并标出流程前置关系；Makefile 命令显示按构建文件推导的执行目录和所需输入路径，资料不足时明确待确认。基础完成检查与仓库原文预期分开展示。 历史执行记录除命令和提交外，还核对已记录的执行目录，不能挪用其他目录的结果。 本轮仅对既有输出作确定性回放，没有新增模型抽样或完整测试结论，详见 `workflow_round3_20261018.md`。

5.7 固定参考与公平对照（第四轮）

两份参考绑定源码 SHA、引用原文与行号，规则检查和三个来源文件的 Git blob 交叉检查通过；它们属于 AI 源码复核，独立人工复核仍待完成。 普通 RAG 改为统一去重索引，路由组关闭专属加分，两个仓库各两次重复完成 36 次模型请求。Requests 的两次参考匹配中，全局与路由持平；Click 专项命令参考与基础测试任务存在评价边界，不据此将拒绝编造判为错误。 对照发现克隆说明可能被安装资料挤出，已为环境阶段保留克隆、依赖和运行时资料位置。随后 4 次请求的 Requests 单例覆盖三项参考命令，不能推广为一般提升。 本轮未新增上游命令执行，模型对照、单例修复和历史实跑分开记录，详见 `evidence_round4_20261018.md`。

5.8 当前产品可靠性与追问核验（2026-10-21）

在线 Requests 文档采集在此前验收中从 2 份恢复至 24 份，现场 AI 请求恢复测试命令和贡献规范；新仓库元信息 API 仍可能限流。追问沿用指南的固定提交，返回已逐字核验的来源、行号与摘录。错误定位中 AI 仅选择相关原文，自由生成的根因断言或新命令不作为回答展示；本地规则提示和原文核验均不证明语义正确或问题已修复。

在线主指南和错误定位均使用单次 HTTP 25 秒、不重试的模型策略；不是端到端总时限。指南支持取消等待，后台处理可能继续。无真人试用结果，独立人工复核仍待完成；本轮不将测试通过数作为新手贡献成功率。

5.9 多仓库检查与实际复现（2026-10-21）

五仓库固定源码检查发现并修复占位符克隆、版本查询误当测试、局部测试范围不明等问题，同时保留 Mocha 环境/测试资料不足及 Click 安装资料不足的缺口。结构化检查不等于流程可执行。

新的两批真实模型对照各 16 组，其中 8 组可计分，失败均保留。Click 仅在明示专项命令提取范围内出现局部匹配差异，Requests 的对应组未完成；不能据此宣称普遍优于普通 RAG。产品侧另作有标记的字符串换行兼容，仍核验引用；同一组真实响应回放后，缺依据的 PR 阶段改为原文规则，专项 CI 安装不作必需步骤。详见 `validation_round9_20261021.md`。

全新目录及虚拟环境按锁文件完成核心安装（23 包，无向量库或凭据），API 健康检查 200，锁定开发环境下 191 项测试通过；前端新目录 10 项测试、lint 与构建通过。缓存被复用，本机无 Docker；容器验证以该提交 CI 为准。向量检索依赖改为可选安装。真人效果、独立人工复核、团队审核和最终演示材料仍待完成。

6. 真实贡献记录（方向三佐证）

L4 记录"用本产品自己走通一个真实 PR"的闭环证据，落盘于 `benchmark/l4_contribution/records.json`，用一行代码补录：

```
from benchmark.l4_contribution.runner import add_record
add_record("owner", "repo", "pr", "https://github.com/owner/repo/pull/123", "用 OpenGuide 走通的文档改进")
```

状态语义（避免"待补充"被误读成"失败"）：

- `PENDING`：尚无记录（退出码 0，明确标注待补充）
- `OK`：已有记录，逐条打印
- `FAIL`：记录文件损坏（真错误）

> **口径**：没有记录就不会被算作"闭环已完成"——报告明确标 `PENDING`，评审一眼可见此项待补。

7. 运行与复现

7.1 一键部署（评审冷启动推荐）

```
cp .env.example .env          # 可选：填 GITHUB_TOKEN / LLM_API_KEY；不填也能跑
docker compose up --build
# 浏览器打开 http://127.0.0.1:5173
```

前端由 nginx 提供静态站点并把 `/api` 反向代理到后端容器（同源，免 CORS）。 默认 `USE_CHROMA=false` 走确定性检索，**零模型下载、秒级启动**，适合离线评审。

7.2 本地开发

```
# 后端
cd backend && uv sync && uv run uvicorn backend.api.main:app --port 8000
# 前端
cd frontend && pnpm install && pnpm dev     # http://127.0.0.1:5173
```

7.3 接口

方法	路径	说明
POST	`/api/profile`	`{url}` → 仓库画像
POST	`/api/search`	`{url, query, kind?}` → 按视角路由的检索结果
POST	`/api/guide`	`{url, use_llm}` → Stage A–D 结构化指南
POST	`/api/followup`	三步追问：这步太粗 / 看不懂为什么 / 报错了
GET/POST	`/api/llm-config`	会话内 LLM 配置（不回显 Key）
GET	`/health`	存活检查

8. 项目路线图与开源计划

8.1 已交付

- 四段管线（M0 勘探 / M1 分层索引 / M2 结构化生成 / M3 分步引导）全部打通
- 四层评测工具（L1–L4）、5 个历史参考仓库及 2 份固定提交参考；独立人工复核待完成，L4 无真实贡献记录
- Docker 一键部署、演示脚本、第三方许可披露、变更记录

8.2 后续计划

方向	内容
评测扩容	golden 集从 5 个扩到 15–20 个，覆盖更多语言与构建系统（Rust / Go / Java）
开源模型对比	用同一评估集对比开源模型与商业模型的输出质量（点题"AI + 开源"，不做过度承诺）
V2 架构视角升级	引入 tree-sitter 符号表，把"改哪个文件"从目录级细化到符号级
追问增强	报错定位接入更多语言生态的规则库
真实贡献	持续用本产品向小仓库提交 PR，滚动更新 L4 记录

8.3 开源计划

本作品以 MIT 许可开源。仓库目前已公开，接受外部 issue 与 PR—— 用自己做的工具来管理自己的新手贡献者，是这个项目最好的验证方式。

9. 隐私、授权与 AI 辅助开发

见 `privacy_and_license.md` 与 `ai_assistance_disclosure.md`。

附：文档索引

文档	内容
`task_book.md`	任务书（选题论证 / 技术方案 / 里程碑）
`demo_script.md`	固定证据主线与在线可选演示
`video_script.md`	演示视频分镜脚本
`code_outline.md`	代码大纲与接口约定
`third_party_disclosure.md`	第三方资源与许可披露
`privacy_and_license.md`	隐私与授权说明
`cold_start_checklist.md`	提交包冷启动演练记录
`evaluation_report.md`	评测报告（L2/L3 实测数字与归因）
`../output/pdf/OpenGuide-  .pdf`	本说明的 PDF 工作稿，待团队审核后定稿
`../tools/render_submission_pdf.py`	PDF 生成脚本（改完 Markdown 后重新生成）
`changelog.md`	变更记录（含修复根因与验证口径）
`../benchmark/README.md`	评测方法论与口径红线